

Análise de Padrões de Escolha e Desempenho de Heróis em Dota 2 por Faixa de Habilidade (MMR)

David Haim Raiber¹ Isadora Caetano Brandão de Sousa¹
Jennifer Aparecida de Sousa Tondade¹ Lucas Lacerda Gomes¹

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

< 10395618@mackenzista.com.br, 10420646@mackenzista.com.br,
10420574@mackenzista.com.br, 10322644@mackenzista.com.br>

2026

Resumo

Este projeto aplica técnicas de Inteligência Artificial para analisar padrões de escolha e desempenho de heróis em Dota 2, um dos MOBAs mais populares do cenário competitivo mundial. Os dados foram coletados diretamente pelo grupo por meio de uma requisição HTTP ao endpoint público heroStats da OpenDota API, contendo o número de picks, vitórias e taxa de vitória de 92 heróis em oito faixas de habilidade (MMR), da categoria Herald até Immortal, e investiga-se como o desempenho de cada herói varia conforme o nível de habilidade dos jogadores. O trabalho justifica-se pela relevância da análise de dados em eSports e por constituir uma base metodológica para o Trabalho de Conclusão de Curso do grupo, voltado à análise de perfis comportamentais de jogadores em Valorant. Como metodologia, foi realizada a extração dos dados via API, seguida de análise exploratória e preparação dos dados em Python, que será seguida, na etapa de modelagem, pela aplicação de clusterização (K-means e clusterização hierárquica) para identificar arquétipos de heróis a partir de seus padrões de popularidade e efetividade, complementada por um modelo Random Forest para prever a taxa de vitória a partir do papel e do atributo primário do herói. Espera-se identificar arquétipos que revelem diferentes graus de dependência da habilidade do jogador, validando uma metodologia reaproveitável para a etapa de desenvolvimento do TCC.

Palavras-chave: Dota 2; eSports; aprendizado de máquina; clusterização; MMR: OpenDota API.

Abstract

This project applies Artificial Intelligence techniques to analyze hero pick and performance patterns in Dota 2, one of the most popular MOBAs in the global competitive scene. The data was collected directly by the group through an HTTP request to the OpenDota API's public heroStats endpoint, containing the number of picks, wins and win rate of 92 heroes across eight skill brackets (MMR), from Herald to Immortal, and this work investigates how each hero's performance varies according to players' skill level. The work is justified by the relevance of eSports analytics and by providing a methodological basis for the group's undergraduate thesis, which addresses player behavioral profiles in Valorant. The methodology included data extraction via API, followed by exploratory analysis and data preparation in Python, to be followed, in the modeling stage, by clustering (K-means and hierarchical) to identify hero archetypes from popularity and effectiveness patterns, complemented by a Random Forest model to predict win rate from hero role and primary attribute. Results are expected to reveal archetypes reflecting different degrees of skill-dependency, validating a reusable methodology for the thesis development stage.

Keywords: Dota 2; eSports; machine learning; clustering; MMR; OpenDota API.

1. Introdução

Desenvolvido pela Valve Corporation, Dota 2 é um dos jogos eletrônicos do gênero MOBA (Multiplayer Online Battle Arena) mais jogados e premiados do cenário de eSports mundial. O jogo conta com 124 heróis jogáveis, cada um com um atributo primário (Força, Agilidade, Inteligência ou Universal) e papéis estratégicos como Carry, Suporte, Iniciador, entre outros. As partidas são classificadas por um sistema de habilidade, o MMR, que distribui os jogadores em oito faixas, de Herald a Immortal. Como em outros jogos competitivos, o desempenho e a popularidade de cada herói, o metajogo, variam conforme atualizações do jogo e o nível de habilidade da população analisada, fenômeno que pode ser investigado com técnicas de aprendizado supervisionado e não supervisionado (RUSSELL; NORVIG, 2021).

A análise de dados de desempenho em jogos competitivos é uma linha de pesquisa relevante tanto para a indústria de eSports, ao embasar decisões de balanceamento por parte dos desenvolvedores, quanto para jogadores e equipes na escolha de heróis. Além disso, por ser aplicado a um jogo distinto do Trabalho de Conclusão de Curso (TCC) de alguns integrantes do grupo, que tem como foco o jogo Valorant, este projeto de prática permite validar, em menor escala, técnicas de coleta de dados via API, pré-processamento, clusterização e aprendizado de máquina que serão posteriormente reaproveitadas e aprofundadas na etapa de desenvolvimento do TCC.

O objetivo geral deste projeto é desenvolver um sistema de análise de dados baseado em aprendizado de máquina para identificar padrões de escolha e desempenho de heróis do Dota 2 nas diferentes faixas de habilidade (MMR) dos jogadores. Os objetivos específicos são:

- Coletar os dados de picks, vitórias e taxa de vitória por herói e por faixa de MMR diretamente da OpenDota API;
- Realizar a análise exploratória dos dados coletados;
- Aplicar técnicas de clusterização (K-means e clusterização hierárquica) para identificar arquétipos de heróis;
- Aplicar um modelo supervisionado (Random Forest) para prever o desempenho de um herói a partir de seus atributos e papéis;
- Avaliar os resultados obtidos por meio de métricas de clusterização e de classificação.

Este projeto adota a Opção Framework, empregando a biblioteca scikit-learn (PEDREGOSA et al., 2011) para a solução de um problema de clusterização e classificação aplicado a dados de jogos digitais competitivos, em linha com o conteúdo abordado na disciplina de Inteligência Artificial.

2. Descrição do Problema

Em jogos competitivos online como Dota 2, o desempenho de um herói, medido por sua taxa de vitória que não é constante ao longo das diferentes faixas de habilidade dos jogadores: um herói pode apresentar boa taxa de vitória entre jogadores iniciantes e desempenho inferior entre jogadores de elite ou o padrão inverso, conforme a complexidade mecânica e estratégica de sua utilização.

Diante desse cenário, o problema de pesquisa deste projeto é: é possível identificar, a partir de dados agregados de picks e vitórias, arquétipos de heróis que revelem diferentes graus de dependência do nível de habilidade do jogador para um bom desempenho? Parte-se da hipótese de que o papel estratégico e o atributo primário de um herói estão relacionados à forma como seu desempenho varia entre as faixas de MMR.

3. Aspectos Éticos e Responsabilidade no Uso da IA

O conjunto de dados utilizado foi coletado pelo próprio grupo por meio de uma requisição HTTP ao endpoint público heroStats da OpenDota API, que não exige autenticação e contém exclusivamente estatísticas agregadas de picks, vitórias e taxa de vitória por herói e por faixa de MMR, sem qualquer informação individualizada de jogadores com identificação, dados pessoais ou histórico de partidas. Dessa forma, não há tratamento de dados pessoais e não se aplicam restrições da Lei Geral de Proteção de Dados (LGPD) quanto a titulares identificáveis.

Ainda assim, algumas responsabilidades no uso da Inteligência Artificial devem ser observadas. Os resultados de clusterização e de predição são de natureza exploratória e não devem ser interpretados como avaliações definitivas do desempenho individual de jogadores, uma vez que a taxa de vitória de um herói também é influenciada por fatores não capturados nos dados, como a composição da equipe adversária e alterações de balanceamento (patches) ao longo do

tempo. Os resultados serão comunicados com cautela, evitando generalizações indevidas, como rotular jogadores de faixas iniciais como ruins em determinado herói, o que poderia reforçar comportamentos tóxicos já observados em comunidades de jogos competitivos. Por fim, as limitações metodológicas identificadas na própria coleta, como o número de heróis retornado pelo endpoint no momento da extração e a ausência de dados na faixa Immortal, foram documentadas na análise exploratória, Notebook 1, e são reforçadas na conclusão do projeto, de modo a garantir uma interpretação responsável dos resultados.

4. Dataset

O conjunto de dados foi coletado diretamente pelo grupo por meio de uma requisição HTTP ao endpoint público GET /api/heroStats da OpenDota API e documentado no início do Notebook 1 contempla estatísticas de 92 heróis do jogo.

Para cada herói, o endpoint retorna o nome, o atributo primário (Força, Agilidade, Inteligência ou Universal), os papéis estratégicos (Carry, Suporte, Durável, Disable, Iniciador, Nuker, entre outros) e, para cada uma das oito faixas de MMR (Herald, Guardian, Crusader, Archon, Legend, Ancient, Divine e Immortal), o número de picks e de vitórias, a partir dos quais a taxa de vitória de cada faixa foi calculada pelo grupo no momento da extração. Na coleta realizada, o endpoint retornou 92 heróis e não os 124 heróis jogáveis atualmente no jogo, uma limitação do próprio endpoint no momento da extração, e não um erro de tratamento, dado que os ids retornados apresentam lacunas, por exemplo, não há registro para o hero_id 24 e não incluem heróis lançados mais recentemente. Além disso, a faixa Immortal foi retornada com 0 picks e 0 vitórias para todos os heróis; o próprio repositório da OpenDota já relata inconsistências pontuais em outros campos desse mesmo endpoint, por exemplo, o campo turn_rate retornado como nulo, o que reforça se tratar de uma limitação de disponibilidade de dados da fonte, não do pipeline do grupo.

A análise exploratória e a preparação dos dados foram realizadas em Python, com as bibliotecas requests para a extração, pandas, numpy, matplotlib e seaborn (McKINNEY, 2018), e incluíram: extração dos dados via API e persistência em CSV; verificação de valores ausentes, duplicados e inconsistências nas colunas numéricas de picks, vitórias e taxa de vitória; transformação da coluna de papéis estratégicos (roles), que contém múltiplos valores separados por vírgula, em variáveis binárias (multi-hot encoding); cálculo do percentual de picks de cada herói normalizado pelo total de picks de cada faixa de MMR disponível, uma vez que o volume de picks difere entre brackets; e engenharia de três variáveis de desempenho: a taxa de vitória média do herói ao longo das faixas com dados (WinRate_Mean), o desvio-padrão da taxa de vitória entre essas faixas, indicando a consistência do herói (WinRate_Std), e a “variação de desempenho”, correspondente à diferença da taxa de vitória do herói entre a faixa mais baixa Herald e a mais alta com dados disponíveis, Divine, utilizada como indicador de dependência de habilidade (WinRate_Delta), a faixa Immortal foi excluída desse cálculo por não conter dados. A normalização/padronização das variáveis numéricas será aplicada antes da execução dos algoritmos de clusterização, na etapa de modelagem que ocorrerá na N2.

Como resultado obtido na análise exploratória, verificou-se que o dataset não possui heróis duplicados, 92 nomes únicos nem casos em que o número de vitórias é superior ao de picks em nenhuma faixa de MMR. A taxa de vitória de todos os heróis situa-se em uma amplitude plausível nas faixas com dados (Herald a Divine), sem outliers fora do esperado,

enquanto a dispersão do número de picks é maior nas faixas extremas com dados (Herald e Divine), que concentram um volume menor de partidas. Confirmou-se ainda que a coluna roles é a única que exige transformação antes da modelagem, por conter múltiplos papéis estratégicos separados por vírgula em uma mesma célula.

5. Metodologia e Resultados Esperados

Esta pesquisa classifica-se como aplicada, de natureza quantitativa, com caráter exploratório e descritivo, caracterizando-se como pesquisa experimental com desenvolvimento de protótipo de software, segundo os critérios de Gil (2002). O desenvolvimento seguiu/seguirá as seguintes etapas: extração dos dados via requisição HTTP à OpenDota API e persistência em arquivo CSV; pré-processamento e análise exploratória com estatísticas descritivas e visualizações; engenharia de features, incluindo o percentual de picks normalizado por bracket e a variação de desempenho de cada herói entre as faixas de MMR disponíveis; aplicação de K-means e de clusterização hierárquica para segmentar os heróis em arquétipos com base em seus padrões de popularidade e desempenho ao longo das faixas de MMR, inspirada na abordagem de Luiz et al. (2025) para análise de composição de personagens em jogos competitivos por equipes; aplicação de um modelo Random Forest para prever a taxa de vitória de um herói a partir de atributo primário, papéis estratégicos e faixa de MMR, em linha com a abordagem de Paramita e Jusak (2025); implementação de todos os modelos com a biblioteca scikit-learn (PEDREGOSA et al., 2011); e avaliação dos resultados por meio de métricas de clusterização (índice de silhueta e Davies-Bouldin) e de classificação/regressão (R^2 e erro médio absoluto); e todo o código-fonte e os dados utilizados neste projeto estão disponíveis no repositório do GitHub do grupo (RAIDER et al., 2026)

Como resultados esperados, pretende-se identificar de 3 a 5 arquétipos de heróis que expressem diferentes graus de dependência da habilidade do jogador para um bom desempenho, por exemplo, heróis “consistentes” em todas as faixas de MMR com dados versus heróis de “alto teto”, cujo desempenho cresce significativamente em faixas mais altas, além de um modelo preditivo capaz de estimar a taxa de vitória relativa de um herói a partir de suas características. Espera-se, sobretudo, que a metodologia de extração via API, pré-processamento e clusterização validada neste projeto de prática sirva de base metodológica reaproveitável para a etapa de modelagem e implementação do sistema inteligente proposto no TCC do grupo, voltado à identificação de perfis comportamentais e de identidade de jogadores a partir da escolha de agentes no jogo Valorant.

6. Referências bibliográficas

GIL, A. C. Como elaborar projetos de pesquisa. 4. ed. São Paulo: Atlas, 2002.

LUIZ, R. et al. Beyond win rates: a clustering-based approach to character balance analysis in team-based games. arXiv, fev. 2025. Disponível em: <https://arxiv.org/abs/2502.01250>.

McKINNEY, W. Python para análise de dados. 2. ed. São Paulo: Novatec, 2018.

OPENDOTA. OpenDota API Documentation — heroStats endpoint. Disponível em: <https://docs.opendota.com/#tag/hero-stats/paths/~1heroStats/get>.

PARAMITA, N. L. P. S.; JUSAK, J. Predicting player performance in Valorant e-sports using Random Forest. International Journal of Research Metaverse, 2025. Disponível em: <https://ijrm.net/index.php/ijrm/article/view/39>.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>.

RAIBER, D. H.; SOUSA, I. C. B. de; TONDADE, J. A. de S.; GOMES, L. L. Repositório do projeto: Análise de Padrões de Escolha e Desempenho de Heróis em Dota 2 por Faixa de Habilidade (MMR). GitHub, 2026. Disponível em: <https://github.com/isacbs/Analise-de-Padrees-em-Dota-2-por-Faixa-de-Habilidade-MMR/tree/main>.

RUSSELL, S.; NORVIG, P. Inteligência artificial: uma abordagem moderna. Rio de Janeiro: LTC, 2021.